

# A New Blind Separation Approach Based on Blind Localization

Liu, Qingwen    Wang, Zengfu

Department of Automation, University of Science & Technology of China, Hefei 230027

**Abstract:** In this paper, a new approach for blind source separation (BSS) based on blind localization is presented, which makes use of the inherent relationship between separation and localization. The approach incorporates the advantages of classical algorithms of BSS and localization. It can not only determine the number of signal sources, which is difficult to deal with by traditional separation algorithms, but also reduce the adaptive learning time. The efficiency of the approach is illustrated by simulation.

**Key words:** Blind source separation, Blind localization, Direction of arrival, Number of signal sources, Convergence time

## 基于盲定位的盲分离新方法

刘庆文 汪增福

(中国科学技术大学自动化系, 合肥 230027)

**提 要:** 本文分析了盲分离与盲定位的内在联系, 提出了基于盲定位指导下的盲分离新方法。该方法在经典盲分离和盲定位算法的基础上, 通过综合盲定位与盲分离各自具有的优点, 解决了以往盲分离算法不能确定信号源数目的问题, 同时减少了传统分离算法的自适应学习时间。仿真实验验证了新方法的有效性。

**关键词:** 盲定位, 盲分离, 波达方向角, 信号源数目, 收敛时间

### 一、引言

盲信号分离 (Blind Signal Separation, BSS) 是利用传感器阵列接收到的多个独立源信号的混合信号直接恢复输入的各独立源信号的一种方法。盲分离可以应用于许多领域, 如语音分离与识别、通信、生物信号处理以及图像处理等。自 90 年代以来盲分离算法已成为信号处理以及智能系统研究的热点之一。常用的算法有最小互信息量算法 (Minimum Mutual Information, MMI)<sup>[12]</sup>、最大熵算法 (Maximum Entropy)<sup>[114]</sup>、最大似然盲信号分离算法 (Maximum Likelihood, ML)<sup>[5]</sup>和独立元分析理论 (Independent Component Analysis, ICA)<sup>[7]</sup>等, 诸多自适应算法<sup>[4-12]</sup>已对现实环境下的各类信号 (如语音、音乐、图像等) 进行了有效的分离。但是大多数算法都是在给定信号源数目的情况下得到的。而且, 自适应算法本身的稳定性不易确定, 自适应学习时间也较长。

另一方面, 盲定位研究如何利用传感器接收的独立源信号的混合信号以确定信号源在空间的几何位置的问题。它的研究较早也较深入, 已有不少经典算法, 如 MUSIC 算法 (Multiple Signal Classification), ESPRIT 算法 (Estimation of Signal Parameters via Rotational Invariance Technique) 等。另外, 在此基础上, 不少改进算法被提出以提高定位的精度、分辨率和定位速率等性能。

盲定位和盲分离虽然得到了广泛的研究, 但是也存在不少问题。例如, 为了解决盲分离算法不能

确定实际信号源数目的问题, 一般多采用人为设定的办法。这样的人为设定不论在理论上还是在实用上都是一个缺憾, 限制了它的实际应用。针对上述问题, 通过分析盲分离与盲定位之间的内在联系, 本文提出了一种基于盲定位指导下的盲分离的新方法以弥补现有方法的一些不足。该方法不仅可以对信号源数目作出估计, 而且从概率的角度来看本文所提出的方法在缩短自适应算法的自适应学习时间 (收敛时间) 方面也具有以往的盲分离算法所无法比拟的优势。

### 二、盲定位模型

下面, 从盲定位指导下的盲分离这一新的研究角度出发对盲分离问题进行分析 and 讨论。首先考虑盲定位的数学模型。

如图 1 所示,  $S_i(t)$  ( $i=1, \dots, N$ ) 是  $N$  个独立的源信




图 1 信号源与传感器的位置关系

号:  $M(M \geq N)$  个传感器排成均匀直线阵,  $X_i(t)$  ( $i=1, \dots, M$ ) 是阵元输出,  $d$  为阵元间距,  $r_i$  ( $i=1, \dots, N$ ) 为第  $i$  个信号源到坐标原点的距离 ( $r_i \gg d, d \leq \lambda/2$ ),  $\theta_i$  ( $i=1, \dots, N$ ) 为第  $i$  个信号源到坐标原点的波达方向角 DOA (Direction of Arrival)。

设  $W_i(t)$  ( $i=1, \dots, M$ ) 是空间白噪声, 方差为  $\sigma^2$ 。  
 $\Delta t_i$  ( $i=1, \dots, M$ ) 是第  $i$  个信号传播到原点所需要的时间。在上述条件下, 传感器输出与源信号之间的关系可以表示为:

$$X(t) = AS(t) + W(t) \quad (1)$$

这里,  $X(t) = [X_1(t + \Delta t_1), \dots, X_M(t + \Delta t_M)]^T$ ,

$$W(t) = [W_1(t), \dots, W_M(t)]^T,$$

$$A = [a(\theta_1), \dots, a(\theta_N)]$$

其中,  $a(\theta_i) = [1, \exp(jkdcos\theta_i), \dots, \exp(j2kdcos\theta_i), \dots, \exp(j(M-1)kdcos\theta_i)]^T$ ,  $k = \omega/v$  ( $\omega$  是信号角频率,  $v$  为波速)。

下面考虑波达方向角 DOA 的估计问题。

假设信号与噪声是零均值的平稳的随机过程, 且信号之间及信号与噪声之间互不相干。

对阵列输出矢量  $X(t)$  进行相关运算, 有:

$$R_x = E[X(t)X(t)^H] = AR_sA^H + \sigma^2 I \quad (2)$$

其中  $^H$  表示共轭转置。求  $R_x$  的特征值, 并按从大到小的顺序排列, 有:  $\lambda_1 \geq \lambda_2 \geq \lambda_3 \geq \dots \geq \lambda_N > \lambda_{N+1} = \dots = \lambda_M = \sigma^2$ ; 再求与  $\lambda_i$  对应的特征向量, 有:  $V_1, \dots, V_M$ 。由矢量  $V_{N+1}, \dots, V_M$  张成噪声子空间, 方向矢量  $a(\theta_1), \dots, a(\theta_N)$  张成信号子空间, 可知两子空间正交互补。运用 MUSIC 算法<sup>[1]</sup>可得到相应的空间-方位谱估计为:

$$P_{music}(\theta) = \frac{1}{\sum_{i=N+1}^M \|a(\theta)^H V_i\|^2} \quad (3)$$

其中,  $V_i$  为特征值等于  $\sigma^2$  所对应的特征向量,  $a(\theta_i)^H = [1, \exp(-jkdcos\theta_i), \dots, \exp(-j(M-1)kdcos\theta_i)]^T$ 。

对式(3)进行扫描, 则可由空间-方位谱的前  $N$  个峰值确定信号源的方位角为  $\theta = [\theta_1, \dots, \theta_N]^T$ 。

为了确定信号源  $S_i(t)$  在空间的位置  $(r_i, \theta_i)$ , 可考虑采用双基站交叉定位的方法<sup>[2]</sup>。

如图 2 所示, 设信号源  $S_i$  位于  $(X_i, Y_i)$ , 从 A(0, 0) 和 B(L, 0) 两个基站分别测出  $S_i$  的方位角为  $\theta_{Ai}$ 、 $\theta_{Bi}$ , 可以得到  $X_i$ 、 $Y_i$  为:

$$X_i = k_2 L / (k_2 - k_1) \quad (4)$$

$$Y_i = k_1 k_2 L / (k_2 - k_1) \quad (5)$$

其中,  $k_1 = \tan \theta_{Ai}$ ,  $k_2 = \tan \theta_{Bi}$ 。

进而求出  $S$  点到 A、B 的距离分别为:

$$r_{Ai} = (X_i^2 + Y_i^2)^{1/2} \quad (6)$$

$$r_{Bi} = ((X_i - L)^2 + Y_i^2)^{1/2} \quad (7)$$

上面给出了对一个信号进行定位的结果。在两个基站同时对  $N$  个信号源测向时, 共有  $N^2$  个可能的




图 2 双基站交叉定位

位置点, 其中只有  $N$  个为真正位置。为去除假定位, 首先进行如下预处理:

设  $A_k$  ( $k=1, \dots, N$ ) 是  $A = [a(\theta_1), \dots, a(\theta_N)]$  中扣除  $a(\theta_k)$  后的矩阵。对  $A_k$  的奇异值分解, 有:

$$A_k = [U_{k1} \ U_{k2}] \begin{bmatrix} \Sigma_k \\ 0 \end{bmatrix} V_k \quad (8)$$

其中,  $\Sigma_k$  是对角阵, 对角线各元素为矩阵  $A_k$  的  $N-1$  个奇异值。由矩阵的奇异值分解性质可知:  $U_{k2}^H A_k = 0$ 。于是得到:

$$\begin{aligned} Y_k &= [U_{k2}^H a(\theta_k)]^H U_{k2}^H X(t) \\ &= [U_{k2}^H a(\theta_k)]^H U_{k2}^H [AS(t) + W(t)] \\ &= [U_{k2}^H a(\theta_k)]^H U_{k2}^H [a(\theta_1)S_1(t) + a(\theta_2)S_2(t) + \dots + \\ &\quad a(\theta_N)S_N(t) + W(t)] \\ &= [U_{k2}^H a(\theta_k)]^H U_{k2}^H a(\theta_k) S_k(t) + [U_{k2}^H a(\theta_k)]^H U_{k2}^H W(t) \\ &= b S_k(t) + [U_{k2}^H a(\theta_k)]^H U_{k2}^H W(t) \end{aligned} \quad (9)$$

其中  $b = [U_{k2}^H a(\theta_k)]^H U_{k2}^H a(\theta_k) = |U_{k2}^H a(\theta_k)|^2$  为实数;  $W(t)$  为噪声矩阵。

以上处理的结果使第  $k$  个信号得到增强。

分别对 A、B 两个基站的所有  $N$  个信号作处理可得到  $[Y_{A1}(t), \dots, Y_{AN}(t)]^T$  与  $[Y_{B1}(t), \dots, Y_{BN}(t)]^T$  两个矢量。对这两个作矢量相关处理, 求其相关系数的模, 得到相关矩阵为:

$$Q = [\rho_{ij}]_{N \times N} \quad (10)$$

由于每个信号与其自身的相关性最强, 只需从  $Q$  的前  $N-1$  行中找到每一行的最大值  $\rho_{ij}$ , 其下标所对应的  $\theta_{Ai}$ 、 $\theta_{Bi}$  即为所求得的真定位。当前  $N-1$  个信号正确定位后, 第  $N$  个信号的位置也就清楚了。

### 三、盲分离模型

如图 3 所示, 从盲定位模型中使用的  $2M$  个传感器中任意选择  $N$  个用于盲分离, 其输出分别记为  $X_j(t)$  ( $j=1, \dots, N$ )。

$X_j(t)$  与  $S_i(t)$  之间的关系由下式给出:

$$X_j(t) = \sum_{i=1}^N a_{ji} S_i(t) \quad (11)$$

$$\text{即} \quad X(t) = AS(t) \quad (12)$$

其中  $A = [a_{ij}]_{N \times N}$  为混合关系矩阵。

显然, 如果我们能用某种方法求出  $A^{-1}$  的估计




图3 盲分离模型

$B(t)$ , 则可用下式分离出源信号  $S(t)$  为:

$$Y(t) = B(t)X(t) = B(t)AS(t) = A^{-1}AS(t) = S(t) \quad (13)$$

其中  $B(t) = [b_{ij}]_{N \times N}$  为自适应网络结构矩阵 (恢复矩阵),  $Y(t) = [Y_1(t), \dots, Y_M(t)]^T$  为分离输出信号矢量。

基于最小互信息量 (Minimum Mutual Information, MMI) 的自适应盲分离算法以分离输出信号之间的互信息量最小为准则, 通过构造以网络结构矩阵  $B(t)$  为自变量的代价函数 (cost function), 并求取该代价函数的最小值来求出  $B(t)$ 。令代价函数为  $Q(t, B(t))$ :

$$Q(t, B(t)) = \int \frac{P(Y) \log(P(Y))}{\prod_{i=1}^N p_i(Y_i)} dY \quad (14)$$

其中,  $P(Y)$  是联合密度函数,  $p_i(Y_i)$  为  $Y_i$  的边缘密度函数。可以证明, 当  $Q$  取最小值时, 分离输出信号  $Y(t)$  之间的互信息量为最小。此时, 相应的  $B(t)$  趋于  $A^{-1}$ , 上述  $B(t)$  可用自适应梯度算法由下式解出<sup>[11]</sup>:

$$B(t+1) = B(t) + \Delta B(t) \\ \Delta B(t) = \eta \{I - f(Y)g(Y)^T\} B(t)^T \quad (15)$$

其中  $\eta$  为学习率因子 (学习步长),  $0 < \eta < 1$ ;  $I$  为单位矩阵;  $f(x) = [f_1(x), \dots, f_M(x)]^T$ ,  $g(x) = [g_1(x), \dots, g_M(x)]^T$ , 常用的  $f(x), g(x)$  有:  $f(x) = x$ ,  $g(x) = x$ ;  $f(x) = x^3$ ,  $g(x) = x$  等。

#### 四、盲定位指导下的盲分离

现在考察式 (1) 和式 (12) 中的矩阵  $A$ , 显然它们具有相同的数学意义。在式 (1) 中  $A$  表示信号源与传感器之间的空间位置关系, 而在式 (12) 中  $A$  则表示源信号的混合关系。因此, 可以认为  $A$  表示由信号源与传感器之间的空间位置关系所确定的信号混合关系。所以, 自适应盲分离算法 (15) 中的  $B(t)$  收敛的过程实质上也是盲定位过程。设 (15) 式中的  $B(t)$  收敛于  $B_0$ , 即:

$$B_0 = \lim_{t \rightarrow \infty} B(t) \quad (16)$$

$$\text{若 } B_0 = A^{-1} \quad (17)$$

$$\text{则 } A = B_0^{-1} \quad (18)$$

当  $B(t)$  收敛于  $B_0$  时, 可以由 (18) 式用  $A = B_0^{-1}$  估计出信号源的位置。反之, 若用盲定位确定了  $A$ , 则由 (17) 式令  $B_0 = A^{-1}$  作为恢复矩阵就可以进行信号分离。

基于上述分析, 我们提出一种基于盲定位的盲分离算法。算法步骤如下:

①在两个基站 A、B 分别用 MUSIC 算法估计信号源的 DOA:  $\theta_A = [\theta_{A1}, \dots, \theta_{AN}]^T$ ,  $\theta_B = [\theta_{B1}, \dots, \theta_{BN}]^T$ ;

②按交叉定位方法估计空间方位矩阵  $A$ ;

③求空间方位矩阵  $A$  的逆矩阵  $A^{-1}$ , 作为分离算法的初值  $B_{init}$ ;

④用 (15) 式的自适应算法进行盲分离, 得到分离输出  $Y(t) = S(t)$ 。

新方法没有把  $A^{-1}$  作为恢复矩阵  $B$  来直接进行盲分离, 而是将  $B_{init} = A^{-1}$  作为自适应算法的初值。这是因为直接使用由  $\theta_A$ 、 $\theta_B$  估计出的  $A^{-1}$ , 不能保证分离输出  $Y(t)$  的 MI (Mutual Information) 最小。而使用自适应算法则可以在理论上保证使上述 MI 达到最小。另外, 自适应算法在噪声足够小以及满足稳定收敛的条件下, 只要学习率因子  $\eta$  (学习步长) 足够小, 可以使盲分离达到较高的精度。这样, 利用自适应算法可以通过调整学习率因子来达到提高收敛精度的目的。

此外, 自适应算法的各种改进算法还能针对源信号为任意概率分布、有多径干扰、未知噪声特性等复杂情况下的信号进行有效的分离, 使新算法在性能的改善方面有很大潜力, 这也是本文采用自适应算法的另一个重要原因。

#### 信号源数目的估计

大多数盲分离算法不能对信号源数目作出估计, 通常要用人为假定的办法来解决这个问题。这是实际运用中的一个缺憾, 实际上这并不是严格意义上的盲分离。本文所提出的方法在对信号源方位角进行估计的同时, 可以根据 (3) 式采用适当算法得到方位谱峰值个数的估计, 即信号源数目的估计, 例如, 设定阈值作为判决标准是最简单的方法。而且用两个基站得到的两个方位谱的数目估计可以利用融合算法进一步提高判决的准确性, 本文不打算就具体的算法进行深入的讨论, 仅仅起个抛砖引玉的作用。

#### 收敛时间

收敛时间是自适应算法的参数从初值出发不断更新, 直至到达收敛稳定点的自适应学习时间。在相同条件下, 收敛时间可以用更新次数  $n$  来度量。

自适应算法对信号的波形恢复程度越高, 要求学习率因子  $\eta$  越小。由 (15) 式可推出自适应算法中恢复矩阵  $B_0$  的估计误差  $\Delta$  为:

$$\Delta = |\Delta B| \leq \text{Max} |\Delta B| \leq \eta \text{Const} \quad (19)$$

可见若要求  $\Delta$  越小, 则要求  $\eta$  越小; 但这样做将导致收敛速率下降, 收敛时间延长。

Amaral 曾提出当取某类特殊的非线性函数作为代价函数时, 自适应算法可以按  $\eta^2$  速率收敛。但是特殊的非线性代价函数必然使每次更新的运算量加大, 使收敛时间延长。另外, 在文献[11]中, 为提高分离程度对代价函数而引入的平滑等也会使收敛时间延长。

我们注意到在相同收敛速率下, 收敛时间与自适应网络初值到收敛点的距离成正相关。下面说明从概率的角度来看新算法在收敛时间方面具有其它方法所不具有的优良性能。

设收敛域中每一点  $(b_{12}, b_{21})$  到收敛点  $(b_{012}, b_{021})$  的距离的期望为:

$$E_g[r] = \int r p(r) db_{12} db_{21} \quad (20)$$

其中  $r = ((b_{12} - b_{012})^2 + (b_{21} - b_{021})^2)^{1/2}$  是  $(b_{12}, b_{21})$  到  $(b_{012}, b_{021})$  的距离;  $p(r) = 1/S$  ( $S$  为收敛域面积)。可以用  $E_g[r]$  作为无定位指导时收敛时间的一个度量。

由定位误差决定的对收敛点  $(b_{012}, b_{021})$  的估计误差为  $\delta_{12}$  和  $\delta_{21}$  (可以通过误差传递求得)。

在区域  $[b_{012} - \delta_{12}, b_{012} + \delta_{12}] \times [b_{021} - \delta_{21}, b_{021} + \delta_{21}]$  中求每一点到收敛点  $(b_{012}, b_{021})$  的距离的期望:

$$E_g[r] = \int r p(r) db_{12} db_{21} \quad (21)$$

其中  $r = ((b_{12} - b_{012})^2 + (b_{21} - b_{021})^2)^{1/2}$  为区域  $[b_{012} - \delta_{12}, b_{012} + \delta_{12}] \times [b_{021} - \delta_{21}, b_{021} + \delta_{21}]$  中每一点  $(b_{12}, b_{21})$  到收敛点  $(b_{012}, b_{021})$  的距离;  $p(r) = 1/S$  ( $S$  为区域  $[b_{012} - \delta_{12}, b_{012} + \delta_{12}] \times [b_{021} - \delta_{21}, b_{021} + \delta_{21}]$  的面积)。用  $E_g[r]$  作为有定位指导时收敛时间的一个度量。

$$\text{定义: } G = E_g[r] / E_c[r] \quad (22)$$

为盲定位指导盲分离的收敛时间衰减度。在定位精度达到一定要求时,  $G$  是小于 1 的正数, 即盲定位指导盲分离使自适应算法收敛时间减少, 仿真实验验证了这一点。

上述算法可以广泛应用于许多领域。例如, 在城市中用相同频段的 AM 无线电传送语音信号。对检波后的语音信号采样频率至多为  $F_s = 4 \times 10^4 \text{ Hz}$ , 即采样时隙为  $T_s = 1/F_s = 2.4 \times 10^{-5} \text{ s}$ 。假设信号源与传感器之间的距离差为  $\Delta l = 10 \text{ km}$ , 则信号传播时间差为  $\Delta t = \Delta l / v = 3.3 \times 10^{-5} \text{ s}$  ( $v = 3 \times 10^8 \text{ m/s}$ )。所以不同传感器接收到的同一源信号至多只有几个采样时隙的时间差。而语音信号中一个音节通常需要至少  $10^2$  数量级的采样点, 所以在这种情况下, 时间差  $\Delta t$  对信号混合关系的影响是可以忽略的。此时  $1/r_{ij}$  ( $r_{ij}$  表示第  $j$  个信号源到第  $i$  个传感器的距离) 是影响信号混合的主要因素, 源信号与传感器之间的关系可以表示为:

$$X(t) = AS(t) \quad (23)$$

$$A = \begin{bmatrix} \frac{1}{r_{11}} & \dots & \frac{1}{r_{1N}} \\ \vdots & \ddots & \vdots \\ \frac{1}{r_{N1}} & \dots & \frac{1}{r_{NN}} \end{bmatrix}_{N \times N}$$

下面, 以此混合模型为例进行了仿真实验。

## 五、仿真实验

为了验证所提出的方法的正确性, 以两个信号源为例, 进行了仿真实验。

实验中设 2 个信号源  $S_1(t)$ 、 $S_2(t)$  到 2 个基站 A、B 的 DOA 分别是  $(\theta_{11}, \theta_{12}) = (30^\circ, 150^\circ)$ ,  $(\theta_{21}, \theta_{22}) = (45^\circ, 165^\circ)$ 。由新算法求得归一化的  $B_0$  元素为:  $b_{011} = b_{022} = 1$ ,  $b_{012} = -0.6$ ,  $b_{021} = -0.4$ 。

文[3]在  $S/N = 10 \text{ dB}$  的实际环境下得到 DOA 的估计误差小于  $0.1^\circ$ 。我们设 DOA 估计误差  $\Delta\theta \leq 5^\circ$ , 由本文方法及误差传递公式推出对  $(b_{012}, b_{021})$  的估计误差分别满足  $\delta_{12} \leq 0.18$  和  $\delta_{21} \leq 0.12$ 。

理论上, 区域  $[b_{012} - \delta_{12}, b_{012} + \delta_{12}] \times [b_{021} - \delta_{21}, b_{021} + \delta_{21}] = [-0.78, -0.42] \times [-0.52, -0.28]$  中每一点到收敛点  $(-0.6, -0.4)$  的距离的期望为:

$$E_g[r] = \int r p(r) db_{12} db_{21} = 0.116$$

当没有定位指导时, 在  $[-1, +1] \times [-1, +1]$  中随机地选取  $(b_{12}, b_{21})$  作为初值, 此时  $[-1, +1] \times [-1, +1]$  中每一点到收敛点  $(-0.6, -0.4)$  的距离的期望 (小于等于在整个收敛域上求得的  $E_g[r]$ ) 为:

$$E_c[r] = \int r p(r) db_{12} db_{21} = 0.987$$

根据 (22) 式, 盲定位指导下的盲分离算法的收敛时间衰减度为:

$$G \leq 0.1175.$$




图 4 (a) 第一个输出信号的 MSE  $\times 10000$




图 4 (b) 第二个输出信号的 MSE  $\times 10000$

在仿真实验中,我们用计算机在 $[-0.78, -0.42] \times [-0.52, -0.28]$ 及 $[-1, +1] \times [-1, +1]$ 中随机地各取20个点 $(b_{12}, b_{21})$ 作为初值,对2个相同的语音信号样本(采样率8kb/s,信号长度都为20000个抽样点(即2.5秒))在上述假设条件下进行混合,并用(15)式算法进行自适应分离(其中 $\eta=0.002$ ;  $f(x)=x$ ,  $g(x)=x$ )。所得均方误差(MSE)如图4所示(细线为无定位指导时输出信号的MSE;粗线为有定位指导时输出信号的MSE)。

从仿真结果看,新方法与原算法相比,相同时刻输出信号的均方误差(MSE)减小,即收敛时间缩短,可以更快地分离出源信号。

## 六、结论

本文提出的基于盲定位的盲分离新方法为研究盲分离问题提出了一个新的角度。新方法不仅能对信号源数目进行估计,而且,从概率意义上可以缩短自适应算法的自适应学习时间(收敛时间)。仿真实验验证了这一点。

本文提出的新方法建筑在经典的盲定位、盲分离算法的基础上,在性能的改善和提高方面潜力很大,具有良好的适应性。

## 参考文献

1. 何振亚, 杨绿溪, 鲁子弈. 非线性 Information 自组织算法的盲源分离机理. 数据采集与处理 1998, 12, Vol. 13, No. 4, p304-308.
2. 高勇, 肖先赐. 无先验信息时去除两基站交叉定位中的假定. 信号处理. 1999, 9, Vol. 15, No. 3, p230-234.
3. 俞靖, 鲍明. 未知噪声背景下多方位角的估计方法. 数据采集与处理. 1999, 6, Vol. 14, No. 2, p144-147.
4. Bell A J, Sejnowski T J. An information-maximization approach to blind separation and blind deconvolution. Neural Computation, 1995, 7(6), p1129-1159.
5. Belouchrani A, Cardoso J F. Maximum likelihood source separation for discrete sources. In Proceeding of DUSIPCO, Edinburg, Scotland, 1994, p768-771.
6. F.Ehlers and H.G.Schuster, Blind Separation of Convolutional Mixtures and an Application in Automatic Speech Recognition in a Noisy Environment. IEEE Transactions on Signal Processing, 1997, Vol 45, No.10, p2608-2612.
7. P.Comon, Independent component analysis - a new concept? Signal Processing, 1994, 36(3), p287-314.
8. Christian Jutten and Jeanny Herault. Blind separation of sources. Part I: An adaptive based on neuromimetic architecture. Signal Processing, 1991, Vol.24, p1-10.
9. Shun-ichi Amari. Superefficiency in Blind Source Separation. IEEE Transactions on Signal Processing, 1999, Vol 47, No.4, p936-944.
10. Mitsuru Kawanoto, Kiyotoshi Matsuoka, Noboru Ohnishi. A method of blind separation for convolved non-stationary signals. Neurocomputing 1998, Vol.22, p157-171.
11. M.Kawamoto, A.K.Barros, A.Mansour, K.Matsuoka, N.Ohnishi. Real world blind separation of convolved non-stationary signals. Proc. of 1st International Workshop on Independent Component Analysis and Signal Separation (ICA'99). 1999, (44-49), p347-352.
12. S.Amari, A.Cichocki, H.H.Yang. A New Learning Algorithm for Blind Signal Separation. In: Advances in Neural Information Processing Systems. Cambridge, MA: MIT Press. 1996, p757-763.